SECRETARIA DE INTELIGÊNCIA ARTIFICIAL, ECONOMIA DIGITAL, CIÊNCIA, TECNOLOGIA E INOVAÇÃO - SIA

GOVERNO DO PIAUÍ
AQUI TEM TRABALHO.
AQUI TEM FUTURO.

Relatório Técnico: Processo de Desenvolvimento de Soluções da Fábrica de Inteligência Artificial

Governo do Estado do Piauí

11 de fevereiro de 2026

Av. Pedro Freitas S/N Bloco I
Centro Administrativo
Bairro São Pedro • CEP: 64018-900
Teresina • Piauí • Brasil

www.pi.gov.br

Sumário

1 Introdução **4**

1.1 Objetivo do Processo 4

1.2 Visão Geral da Metodologia Lean R&D Adaptada 5

1.3 Workflow Técnico e Integração com a Governança 6

2 Processo da Fábrica de IA **7**

2.1 Fase I – Exploração 7

2.2 Fase II – Viabilidade e Concepção 12

2.3 Fase III – Desenvolvimento de MVP 20

2.4 Fase IV – Piloto Controlado 23

2.5 Fase V – Escala e Operação 25

3 Perfis Técnicos Envolvidos **29**

3.1 Perfis Técnicos Envolvidos 30

3.1.1 Engenheiro de Dados 30

3.1.2 Engenheiro de Machine Learning 31

3.1.3 Engenheiro de Software 33

3.2 Alinhamento com o Workflow de Machine Learning 34

3.3 Alinhamento com o Processo da Fábrica de IA 34

3.4 Síntese de atuação por perfil e fase 35

A Portfólio de Problemas e Oportunidades de IA **37**

A.1 Capa / Identificação 37

A.2 Contexto e Objetivo do Documento 38

A.2.1 Como utilizar este documento 38

A.3 Mapeamento de Dores e Oportunidades 38

A.4 Análise de Viabilidade e Triagem Técnica 39

A.5 Matriz de Priorização e Subsídios para Decisão 40

A.6 Validação e Assinaturas 41

B Detalhamento do Problema Priorizado **42**

B.1 Introdução 43

B.2 1. Contextualização Detalhada do Problema 43

B.3 2. Objetivos Pretendidos 44

B.4 3. Principais Stakeholders Envolvidos 44

B.5 4. Hipótese Inicial de Uso de IA 44

B.6 5. Inventário Preliminar de Dados 45

B.7 6. Análise Inicial de Riscos e Conformidade 45

B.8 Decisão do Comitê Gestor 46

C Relatório de Viabilidade **47**

C.1 Introdução e Objetivo 47

C.2 Dimensão: Viabilidade Técnica 47

C.2.1 Qualidade e Disponibilidade dos Dados (Resumo EDA) 47

C.2.2 Infraestrutura Computacional Necessária 49

C.3 Dimensão: Viabilidade Científica 49

C.3.1 Adequação Metodológica e Estado da Arte 49

C.3.2 Resultados da Prova de Conceito (PoC) 50

C.3.3 Riscos de Confiabilidade e Robustez 50

C.3.4 2.2 Riscos de Modelagem e Generalização 50

C.4 Dimensão: Viabilidade Operacional 51

C.4.1 3.1 Integração com Legado e Fluxos de Trabalho 51

C.4.2 3.2 Capacidade de Manutenção e Sustentação 51

C.5 4. Consolidação de Riscos e Limitações 51

C.6 5. Parecer Final para Decisão de MVP 52

Capítulo 1

Introdução

1.1 Objetivo do Processo

Este documento define o processo padronizado de desenvolvimento de soluções da Fábrica de Inteligência Artificial (IA) do Governo do Estado do Piauí. O processo é baseado na metodologia **Lean R&D**, conforme proposta por Kalinowski, adaptada ao contexto da administração pública estadual e ao desenvolvimento de soluções de IA preditiva e generativa. O objetivo é garantir previsibilidade, aprendizado contínuo, alinhamento estratégico e entrega incremental de valor aos órgãos demandantes.

Do ponto de vista de modelos clássicos de mineração de dados, o processo aqui definido é compatível com o CRISP-DM [8], preservando sua estrutura iterativa baseada em: (i) compreensão do problema e definição de objetivos, (ii) compreensão e preparação dos dados, (iii) modelagem, (iv) avaliação e (v) implantação. A Fábrica de IA organiza essas atividades em fases com artefatos e critérios de saída explícitos, de modo a reforçar governança, rastreabilidade e previsibilidade no contexto do setor público.

O processo integra:

- As **fases do Lean R&D**;
- As **etapas do workflow de Machine Learning (ML)**;
- Os **perfis técnicos e competências necessárias**.

O processo é **padronizado** e aplicável a todos os projetos da Fábrica de IA.

1.2 Visão Geral da Metodologia Lean R&D Adaptada

O processo da Fábrica de IA fundamenta-se nos princípios da metodologia Lean R&D, originalmente proposta para gerir a incerteza inerente a projetos de pesquisa e desenvolvimento em transformação digital [5]. Diferente do desenvolvimento de software tradicional, no qual os requisitos são frequentemente determinísticos, o desenvolvimento de Sistemas Baseados em Aprendizado de Máquina (*ML-enabled systems*) possui natureza probabilística e experimental, exigindo uma abordagem que priorize a validação rápida de hipóteses.

No entanto, a aplicação desta metodologia no âmbito do Governo do Estado do Piauí exige adaptações críticas para atender à natureza do setor público. Enquanto o R&D industrial foca prioritariamente em retorno financeiro e *time-to-market*, o processo da Fábrica de IA foi ajustado para considerar três pilares contextuais:

- **Orientação ao Valor Público:** as iniciativas não buscam apenas lucro, mas atender a demandas orientadas a políticas públicas e serviços essenciais, em que o impacto social e a melhoria da qualidade de vida do cidadão são as métricas de sucesso primárias.
- **Dependência e Sensibilidade de Dados:** há forte dependência de dados institucionais, que muitas vezes residem em silos legados e exigem tratamentos rigorosos de privacidade e curadoria antes de serem aptos para modelagem.
- **Rigor em Governança e Ética:** diferente de experimentações privadas, o uso de IA no governo impõe estrita necessidade de governança, transparência e ética algorítmica.Para operacionalizar esse requisito, a metodologia integra nativamente o Framework de Autoavaliação de Impacto Ético (AIE) do Governo Federal [3].

Além disso, o processo foi desenhado para estar em conformidade antecipada com o Marco Legal da Inteligência Artificial (PL 2338/2023) [2]. Para materializar essa conformidade na prática, adotamos o Framework de Autoavaliação de Impacto Ético (AIE) [3] como ferramenta de controle. Reconhecendo que o Estado é um fornecedor de alto impacto, a metodologia integra os fundamentos de centralidade da pessoa humana, não discriminação e transparência (Art. 2º do PL) como requisitos não-funcionais obrigatórios, verificados sistematicamente através dos questionários do framework.

Dessa forma, a metodologia opera como um funil de inovação responsável, no qual múltiplas ideias são exploradas com baixo custo na fase inicial, mas apenas aquelas que comprovam viabilidade técnica, aderência aos dados institucionais e conformidade ética progridem para as fases de desenvolvimento e escala.

1.3 Workflow Técnico e Integração com a Governança

Enquanto a metodologia Lean R&D fornece a estrutura de governança e decisão (o "quê"e "quando"fazer), a execução técnica dos projetos segue um fluxo de trabalho especializado para Ciência de Dados (o "como"fazer).

Para a Fábrica de IA, adotamos o workflow de 9 estágios para Engenharia de Software em IA [1], que reconhece que o desenvolvimento de ML é fundamentalmente diferente do desenvolvimento de software tradicional em três aspectos:

- **Dependência de Dados:** o comportamento do sistema não é definido apenas por código, mas pela complexa interação entre código e dados de treinamento.
- **Iteratividade Contínua:** o processo não é linear; é comum retroceder fases (por exemplo, voltar à coleta de dados após perceber falhas na avaliação do modelo).
- **Experimentação:** falhas são esperadas e tratadas como insumo para refinamento.

O fluxo técnico, que permeia todas as fases de gestão, é composto pelas seguintes macro-etapas:

- **Orientação a Dados:** coleta, limpeza e rotulagem. Esta é frequentemente a etapa mais custosa, exigindo colaboração estreita com os órgãos públicos detentores da informação.
- **Orientação a Modelo:** engenharia de atributos, seleção de modelo, treinamento e avaliação. Aqui, métricas técnicas (por exemplo, acurácia e F1-score) são traduzidas para métricas de negócio.
- **Orientação a Implantação:** integração, monitoramento e observabilidade. O foco é garantir que o modelo continue performando bem no mundo real, mitigando fenômenos como *data drift*.

A dinâmica do processo: na prática, as Fases de Gestão (I a V) funcionam como "contêineres". Dentro de cada fase, a equipe técnica executa iterações deste workflow. Por exemplo, na Fase II (Viabilidade), a equipe executa uma versão rápida do workflow focada em demonstrar que o modelo aprende; já na Fase V (Escala), o workflow é executado com rigor total de MLOps e segurança.

Capítulo 2

Processo da Fábrica de IA

Nesta seção é definido o processo adotado pela Fábrica de IA, fundamentado na integração entre técnicas de Lean R&D, conforme sistematizadas por Kalinowski et al. no contexto da Engenharia de Software para Ciência de Dados [4], e o workflow tradicional de Machine Learning descrito em estudos empíricos sobre sistemas de ML em produção [1]. Essa abordagem estabelece uma visão unificada que combina práticas de exploração, experimentação e aprendizado incremental, características do Lean R&D [4], com as etapas consolidadas do ciclo de vida de sistemas baseados em ML, conforme o workflow empírico identificado por Amershi et al. [1].

Além de estruturar o desenvolvimento técnico de soluções de Inteligência Artificial, o processo definido possui um valor institucional relevante para o setor público. Ao explicitar fases, responsabilidades e artefatos, o modelo contribui para o fortalecimento da governança, para a previsibilidade de investimentos em IA e para a mitigação de riscos associados a iniciativas experimentais. Ademais, a articulação entre Lean R&D e o workflow de ML favorece o alinhamento das iniciativas da Fábrica de IA com políticas públicas de transformação digital, transparência e inovação orientada a dados, reforçando seu caráter estratégico como instrumento de apoio à tomada de decisão governamental.

O processo resultante define, para cada fase, artefatos de saída que formalizam decisões estratégicas, análises técnicas e produtos intermediários. Esses artefatos asseguram rastreabilidade, transparência decisória e transferência de conhecimento entre a Fábrica de IA e os órgãos demandantes, além de funcionarem como insumos estruturados para as fases subsequentes do ciclo de desenvolvimento.

2.1 Fase I – Exploração

Identificar, estruturar e priorizar um portfólio de potenciais projetos de Inteligência Artificial (MVPs) a partir de demandas reais dos órgãos do governo estadual. Esta fase tem como objetivo garantir

o alinhamento estratégico das iniciativas com as prioridades institucionais, avaliar sua viabilidade inicial e concentrar esforços em problemas com elevado potencial de impacto público. Em outras palavras, seu propósito é duplo: atuar como filtro de viabilidade para evitar desperdício de recursos públicos e, simultaneamente, mapear oportunidades de alto valor para compor o Portfólio de Soluções de IA do Estado.

Conforme evidenciado em estudos empíricos sobre engenharia de software para sistemas de Machine Learning, decisões tomadas nesta fase inicial têm impacto direto no custo, no risco e na sustentabilidade das soluções ao longo de todo o ciclo de vida. Esse impacto decorre, sobretudo, da centralidade dos dados, do caráter experimental dos modelos e da existência de múltiplos ciclos de retroalimentação, aspectos apontados por Amershi et al. [1] como diferenças essenciais em relação ao desenvolvimento de software tradicional.

Questões-chave respondidas

As questões a seguir orientam tanto a priorização das iniciativas quanto a decisão explícita de não seguir adiante com determinados problemas, reforçando o papel desta fase como um filtro estratégico e técnico do portfólio da Fábrica de IA.

- Quais problemas, processos ou atividades do órgão são candidatos à aplicação de soluções baseadas em IA?
- Quais desses problemas apresentam maior potencial de impacto público, eficiência operacional ou melhoria da tomada de decisão?
- Qual o nível de complexidade técnica, organizacional e de governança associado a cada problema identificado?
- Quais iniciativas devem ser priorizadas para desenvolvimento pela Fábrica de IA, considerando impacto, viabilidade e alinhamento estratégico?

Atividades detalhadas

As atividades desta fase refletem boas práticas consolidadas na literatura de Engenharia de Software para Machine Learning, reconhecendo que projetos de IA diferem substancialmente do desenvolvimento de software tradicional, sobretudo pela dependência crítica de dados, pela necessidade de experimentação contínua e pela dificuldade de modularização dos componentes de ML [1].

As atividades são organizadas em macroblocos, de forma a facilitar a leitura gerencial sem perda de rigor técnico:

(I) Diagnóstico organizacional e ideação

- Planejamento e condução de workshop estruturado de ideação e diagnóstico, com participação de gestores, especialistas de domínio do órgão demandante e equipe técnica da Fábrica de IA;
- Levantamento sistemático de problemas, gargalos operacionais, riscos e oportunidades de automação ou apoio à decisão orientado por dados;
- Discussão guiada sobre possibilidades de aplicação de IA, considerando abordagens preditivas, generativas ou híbridas e sua aderência ao contexto institucional.

(II) Análise preliminar de dados e viabilidade técnica

- Análise preliminar da disponibilidade, acessibilidade, qualidade, atualidade e governança dos dados necessários para cada problema identificado, reconhecendo que a descoberta, coleta, curadoria e versionamento de dados constituem um dos principais fatores de risco e esforço em projetos de IA, sendo consistentemente apontados como desafios centrais em estudos de engenharia de software para ML [1];
- Estimativa inicial da complexidade dos problemas, considerando aspectos relacionados a dados, modelagem, integração com sistemas existentes e requisitos de governança, ética e conformidade legal, bem como a possibilidade de efeitos não lineares, acoplamento (*entanglement*) entre modelos e comportamento não monotônico de erros, fenômenos amplamente documentados na literatura de sistemas de ML em produção [1].

(III) Priorização e aprofundamento do problema selecionado

- Priorização conjunta dos problemas pelo órgão demandante, com apoio metodológico da Fábrica de IA, a partir de critérios previamente acordados, como impacto, viabilidade, urgência e valor estratégico;
- Para a atividade priorizada, condução de uma atividade específica de aprofundamento e refinamento, inspirada nas práticas de definição de requisitos de modelos de ML descritas na literatura, que enfatizam a explicitação precoce de hipóteses, critérios de avaliação e trade-offs [1], com o objetivo de detalhar de forma mais precisa o problema selecionado, seus objetivos, escopo, restrições, atores envolvidos, critérios de avaliação preliminares e pressupostos iniciais. Essa atividade busca reduzir incertezas iniciais, explicitar hipóteses e tornar explícitos os trade-offs esperados, preparando o problema de forma mais robusta para as fases de Concepção e Viabilidade.

Artefatos de saída

- **Documento de Portfólio de Problemas e Oportunidades de IA**, contendo:
  - Lista consolidada dos problemas identificados;
  - Descrição sucinta e padronizada de cada problema;
  - Estimativa preliminar de complexidade (baixa, média ou alta);
  - Avaliação do potencial de impacto público;
  - Grau de prioridade definido pelo setor demandante.
- **Documento de Detalhamento do Problema Prioritário**, contendo:
  - Contextualização detalhada do problema;
  - Objetivos pretendidos com a solução;
  - Principais stakeholders envolvidos;
  - Indicadores preliminares de sucesso e valor público;
  - Hipótese inicial de uso de IA;
  - Inventário preliminar de dados disponíveis e fontes potenciais;
  - Análise inicial de riscos, incluindo aspectos de dados, ética e conformidade com a LGPD.

Critérios de saída da fase

- Portfólio de problemas formalizado e validado pelo órgão demandante;
- Problemas priorizados conforme critérios acordados entre o órgão e a Fábrica de IA;
- Avaliação explícita de viabilidade e impacto das iniciativas analisadas, podendo resultar na decisão de não continuidade de problemas considerados inviáveis ou de baixo impacto;
- Seleção de um problema prioritário com nível de detalhamento suficiente para avançar para as fases de Concepção e Viabilidade.

Etapas do workflow de ML envolvidas

Nesta fase, não há ainda desenvolvimento ou treinamento de modelos, mas são estabelecidas as bases conceituais, técnicas e organizacionais que orientam todo o workflow de Machine Learning subsequente. As principais etapas do workflow de ML impactadas na fase de Exploração são:

- **Definição do problema e dos requisitos do modelo:** compreensão do problema a ser resolvido, com a definição preliminar dos objetivos da solução, dos tipos de decisão

a serem apoiados ou automatizados e das saídas esperadas do modelo. Em consonância com o PerspecML, essa definição inicial deve explicitar diferentes perspectivas relevantes (por exemplo, negócio/política pública, dados, modelagem, operação e aspectos humanos), permitindo identificar precocemente requisitos funcionais e não funcionais, restrições e trade-offs. Essa atividade está alinhada às etapas iniciais de *Model Requirements* no workflow empírico de sistemas de ML em produção [1] e Entendimento do Negócio [8].

- **Entendimento inicial dos dados (data understanding):** identificação das fontes de dados disponíveis ou potenciais, avaliação preliminar de sua natureza (estruturados, semiestruturados, não estruturados), volume, cobertura temporal, qualidade percebida e limitações conhecidas. Esta atividade subsidia decisões sobre viabilidade e complexidade, sem ainda envolver coleta ou preparação sistemática de dados, sendo consistente com as etapas de *Data Understanding* do CRISP-DM [10] e com evidências empíricas que apontam dados como principal fator de risco em sistemas de ML em produção [1, 6]: identificação das fontes de dados disponíveis ou potenciais, avaliação preliminar de sua natureza (estruturados, semiestruturados, não estruturados), volume, cobertura temporal, qualidade percebida e limitações conhecidas. Esta atividade subsidia decisões sobre viabilidade e complexidade, sem ainda envolver coleta ou preparação sistemática de dados.

- **Definição preliminar de métricas e critérios de avaliação:** discussão inicial sobre como o sucesso de uma futura solução baseada em ML será avaliado, contemplando métricas técnicas (ex.: acurácia, erro, cobertura), métricas de negócio ou de política pública, bem como possíveis impactos éticos, legais e sociais. Em consonância com o CRISP-DM, essas definições são estabelecidas ainda na fase de entendimento do problema e orientam escolhas futuras de modelagem e experimentação, além de alinhar expectativas entre os envolvidos e reduzir retrabalho nas fases subsequentes de validação [10, 1].

- **Análise inicial de riscos do sistema de ML:** identificação antecipada de riscos associados ao uso de dados, à qualidade das predições, a vieses, a efeitos sistêmicos decorrentes da integração do modelo em processos organizacionais e a requisitos de conformidade (ex.: LGPD). Esta análise é fundamental para evitar acúmulo de dívida técnica e riscos sistêmicos, conforme discutido em estudos clássicos sobre sistemas de ML em produção [7, 1]: identificação antecipada de riscos associados ao uso de dados, à qualidade das predições, a vieses, a efeitos sistêmicos decorrentes da integração do modelo em processos organizacionais e a requisitos de conformidade (ex.: LGPD). Essa análise informa tanto a priorização quanto o nível de aprofundamento necessário nas fases seguintes.

De forma geral, a fase de Exploração atua como um filtro estratégico e técnico do workflow de ML, reduzindo incertezas, evitando investimentos prematuros em soluções inviáveis e garantindo que apenas problemas bem compreendidos e alinhados avancem para as fases de Concepção e Viabilidade.

Em consonância com a abordagem de Lean R&D, os resultados desta fase devem ser submetidos à apreciação de um comitê gestor da Fábrica de IA. Cabe a esse comitê avaliar criticamente a visão construída, os artefatos produzidos e as evidências de impacto e viabilidade apresentadas,

deliberando de forma explícita pela aprovação ou rejeição das iniciativas analisadas. Em particular, o comitê gestor é responsável por decidir se o MVP selecionado está suficientemente maduro e alinhado às prioridades institucionais para avançar para as fases subsequentes de Concepção e Viabilidade, caracterizando um ponto formal de decisão no processo.

Adicionalmente, esta fase cumpre papel equivalente à *Compreensão do Negócio* do CRISP-DM, ao estruturar objetivos, escopo, restrições e critérios de sucesso, e também incorpora elementos de *ompreensão dos Dados*, ao realizar um entendimento inicial das fontes, limitações e riscos associados aos dados disponíveis.

2.2 Fase II – Viabilidade e Concepção

Se a Fase I validou o "problema", a Fase II tem a missão de validar a "solução". O objetivo é mitigar o risco técnico (o modelo consegue aprender com os dados disponíveis?) e o risco de design (é possível densenvolver uma solução que se integra aos processos do Estado?). A Fase II compreende as atividades de **Concepção e Viabilidade** da solução. Trata-se de uma etapa fundamental, que antecede o desenvolvimento do MVP, e tem como objetivo principal avaliar, de forma estruturada, se uma solução de Inteligência Artificial é **tecnicamente possível, cientificamente adequada e operacionalmente viável**, antes de aprofundar sua definição conceitual e investir em implementação.

Conforme definido na proposta original do Lean R&D [5], as atividades de Concepção e Viabilidade são independentes do ponto de vista conceitual, mas executadas em paralelo e de forma iterativa. Nesta fase, entretanto, a análise de Viabilidade assume papel orientador inicial, fornecendo evidências sobre dados, riscos e restrições que influenciam diretamente a construção e o refinamento da Concepção.

Em projetos de Inteligência Artificial, decisões tomadas nesta etapa têm impacto significativo sobre custo, risco, qualidade e sustentabilidade da solução. Diferentemente do desenvolvimento de software tradicional, sistemas de IA dependem fortemente de dados, demandam ciclos frequentes de experimentação e estão sujeitos a problemas como vieses, degradação de desempenho e efeitos inesperados quando integrados a processos reais. Assim, a Fase II atua como um mecanismo de redução de riscos, garantindo que apenas soluções viáveis e bem fundamentadas avancem no ciclo de desenvolvimento.

Nesse contexto, a *Viabilidade* avalia se a solução pode ser construída com os dados, tecnologias e recursos disponíveis, enquanto a *Concepção*, informada por essas evidências, foca na definição do problema, do caso de uso e do valor esperado da solução. A interação contínua entre essas atividades permite ajustes progressivos, aprendizado incremental e decisões mais bem embasadas.

Propósito da fase

O propósito da Fase II é **subsidiar a decisão de avançar ou não para o desenvolvimento do MVP, por meio da definição clara do caso de uso de IA e da avaliação objetiva de sua viabilidade com base nos dados e recursos disponíveis**. Assim, busca-se reduzir riscos de insucesso, retrabalho e desperdício de recursos públicos, ao mesmo tempo em que se fortalecem a governança e a previsibilidade das iniciativas da Fábrica de IA.

Além disso, esta fase tem como objetivo tornar explícitas as principais hipóteses, limitações e trade-offs da solução, deixando claras as decisões que orientarão as próximas etapas do ciclo de vida do sistema de IA.

Atividades da fase

As atividades da Fase II estão organizadas em dois grandes blocos, executados em paralelo, conforme a abordagem do Lean R&D: **(I) Viabilidade** e **(II) Concepção**. Essa organização facilita a compreensão do processo e mantém o rigor técnico necessário ao desenvolvimento de soluções de IA.

(I) Viabilidade Essa atividade tem como objetivo avaliar se a solução concebida pode ser implementada na prática, considerando os dados disponíveis, as tecnologias existentes, os recursos necessários e os prazos envolvidos. Essa avaliação é essencial para decidir se o projeto deve avançar para a fase de desenvolvimento.

Dimensões de Viabilidade Avaliadas

- **Viabilidade técnica:** avaliação da qualidade, volume e disponibilidade dos dados (por exemplo, existência de histórico suficiente, completude e atualização periódica), da adequação das técnicas e algoritmos de IA ao problema, bem como das necessidades de infraestrutura computacional (capacidade de processamento, armazenamento, requisitos de latência e disponibilidade de ambientes de execução);
- **Viabilidade científica:** análise da adequação metodológica da abordagem proposta, dos riscos técnicos associados à modelagem (por exemplo, sobreajuste, escassez de dados rotulados ou dependência excessiva de variáveis sensíveis) e do potencial de generalização dos modelos para novos contextos, períodos ou unidades organizacionais;
- **Viabilidade operacional:** verificação da capacidade de implantação da solução no contexto do órgão demandante, incluindo integração com sistemas legados, adaptação aos fluxos de trabalho existentes, necessidade de capacitação de usuários e viabilidade de manutenção e evolução da solução ao longo do tempo.

Atividades da Viabilidade

1. **Levantamento e análise das fontes de dados disponíveis:** consiste na identificação das bases de dados potencialmente relevantes para o problema, avaliando sua origem (sistemas transacionais, bases administrativas, sensores, dados abertos ou terceiros), cobertura temporal e populacional, periodicidade de atualização e mecanismos de governança. Por exemplo, em um sistema preditivo no setor público, pode-se analisar dados históricos de contratos, registros de execução orçamentária e bases de controle externo, verificando restrições legais, lacunas temporais e dependência de múltiplos órgãos.

2. **Realização de análise exploratória dos dados (EDA):** envolve a inspeção inicial dos dados com técnicas estatísticas e visuais para identificar distribuições, correlações, outliers e padrões inesperados. A EDA permite validar hipóteses iniciais e revelar limitações estruturais do conjunto de dados, como forte desbalanceamento entre classes ou baixa variabilidade informacional. Conforme relatado por Amershi et al., essa etapa frequentemente revela limitações que impactam diretamente a formulação do problema, como classes raras, dados desbalanceados ou proxies inadequados para o fenômeno de interesse [1].

3. **Avaliação da qualidade dos dados:** inclui a análise de aspectos como completude, consistência, duplicidade, atualidade e presença de vieses estruturais. Estudos destacam que vieses introduzidos durante coleta, amostragem ou rotulagem tendem a se propagar ao longo do ciclo de vida do sistema de ML, comprometendo desempenho e equidade [9]. Um exemplo típico é a sub-representação de determinados grupos ou contextos nos dados históricos.

4. **Análise preliminar das necessidades de engenharia de atributos:** busca identificar se os dados brutos disponíveis são diretamente utilizáveis ou se demandam transformações adicionais, agregações temporais, normalizações ou construção de atributos derivados. A forma como atributos são representados condiciona diretamente o tipo de modelo viável e o conhecimento que pode ser extraído [11]. Assim, essa análise permite estimar esforço técnico e complexidade futura, além de antecipar dependências de conhecimento de domínio.

5. **Definição da arquitetura conceitual da solução de IA:** consiste no delineamento dos principais componentes da solução, incluindo fluxos de dados, módulos de pré-processamento, modelos de ML, interfaces de integração e mecanismos de monitoramento. Essa arquitetura é definida em nível conceitual, servindo como base para decisões posteriores de implementação e infraestrutura.

6. **Seleção inicial de algoritmos e abordagens de modelagem:** envolve a escolha preliminar de famílias de modelos (por exemplo, modelos lineares, árvores de decisão, ensembles ou redes neurais), considerando trade-offs entre desempenho preditivo, interpretabilidade, custo computacional e facilidade de manutenção. Conforme discutido por Amershi et al., escolhas prematuras ou inadequadas nessa etapa tendem a gerar ciclos extensos de retrabalho, especialmente quando não há alinhamento entre objetivos do modelo e características dos dados [1].

7. **Definição de métricas técnicas para avaliação dos modelos:** inclui a seleção de métricas alinhadas ao objetivo do sistema e às características dos dados, como acurácia, precisão, recall, métricas de custo ou estabilidade temporal. A definição antecipada dessas métricas é fundamental para evitar avaliações desalinhadas com o valor esperado do sistema e para orientar decisões futuras de modelagem e validação.

8. **Identificação de riscos técnicos e organizacionais e estratégias de mitigação:** contempla riscos relacionados à disponibilidade de dados, escalabilidade, dependência de especialistas, aceitação organizacional e integração com processos existentes. Em consonância com o Lean R&D, são propostas estratégias de mitigação, como experimentos exploratórios, escopo reduzido ou hipóteses explícitas a serem validadas [5].

9. **Planejamento do MVP:** envolve a definição do escopo mínimo viável da solução, dos recursos humanos e tecnológicos necessários, do cronograma de execução e dos critérios objetivos de sucesso. O MVP é concebido como um experimento controlado, cujo objetivo principal é reduzir incertezas críticas antes da ampliação da solução.

Artefatos da Viabilidade

- Documento de Viabilidade Técnica, Científica e Operacional, contendo evidências, limitações e recomendações;
- Relatório de Análise Exploratória de Dados (EDA);
- Definição das métricas técnicas de avaliação e critérios mínimos de desempenho aceitável;
- Plano preliminar de desenvolvimento do MVP, condicionado à validação da viabilidade.

(II) Concepção A **Concepção** tem como foco compreender profundamente o problema a ser tratado e definir, de forma clara e compartilhada, a solução de Inteligência Artificial proposta. Nessa atividade, busca-se alinhar expectativas, objetivos institucionais e resultados esperados.

Objetivos da Concepção

- Compreender o problema de negócio, administrativo ou de política pública;
- Definir o escopo da solução de IA, seus objetivos e limitações;
- Identificar o valor público, organizacional ou social esperado;
- Definir requisitos funcionais e não funcionais de alto nível;
- Estabelecer critérios iniciais de sucesso e impacto.

Atividades da Concepção

- Análise do contexto institucional e organizacional, considerando normas, diretrizes estratégicas e expectativas dos gestores e usuários;
- Mapeamento do processo atual, identificando gargalos, ineficiências e oportunidades de melhoria com apoio de IA;
- Formulação clara do problema, distinguindo objetivos de negócio, objetivos do sistema e objetivos do modelo de Machine Learning [1];
- Identificação e análise dos stakeholders, como usuários finais, especialistas de domínio, gestores e equipes técnicas;
- Especificação do caso de uso de IA, incluindo entradas, saídas, decisões apoiadas ou automatizadas e limitações da solução;
- Definição preliminar de requisitos não funcionais relevantes para sistemas de IA, como explicabilidade, confiabilidade, privacidade e justiça [9];
- Definição de indicadores iniciais de valor e impacto.

Artefato de saída: documento de Especificação Técnica contendo a arquitetura da solução e os requisitos validados em todas as perspectivas acima.

Artefatos da Concepção

- Documento de Especificação do Caso de Uso de IA, refinado a partir das evidências de viabilidade;
- Descrição formal do problema, dos objetivos do sistema e das decisões apoiadas pela IA;
- Lista de requisitos funcionais e não funcionais de alto nível, priorizados conforme riscos e restrições identificadas;
- Diagrama de Arquitetura de Solução, mostrando o fluxo de dados desde a origem até o dashboard do usuário;
- Mockups de Interface, contendo telas validadas pelo usuário final;
- Proposta consolidada de métricas de impacto e critérios de sucesso, alinhada às evidências técnicas.

Aplicação do PerSpecML

Para estruturar esta especificação de forma sistêmica, sugere-se a adoção da abordagem PerSpecML [9], que organiza os requisitos técnicos em cinco perspectivas essenciais:

1. **Perspectiva de Objetivos do Sistema (System Objectives)**

   Define o "contrato de sucesso"da aplicação.

   - **Métricas de Negócio vs. Técnicas:** formalização da relação entre o KPI público (por exemplo, "reduzir em 20% o tempo de concessão de benefício") e o *threshold* do modelo (por exemplo, "precisão mínima de 90% para automação total; entre 70–90% para sugestão assistida").
   - **Restrições de Falha:** definição da tolerância ao erro. Qual é o custo de um falso positivo versus um falso negativo? (Por exemplo, em detecção de câncer, um falso negativo é inadmissível; em recomendação de cursos, é tolerável).

2. **Perspectiva de Interação e UX (User Interaction)**

   Define como a inteligência do modelo é entregue ao servidor público ou cidadão.

   - **Modalidade de Interação:** o sistema será passivo (o usuário pede a análise) ou proativo (o sistema alerta sobre anomalias em tempo real)?
   - **Apresentação da Predição:** o modelo entregará apenas o resultado (por exemplo, "fraude") ou uma probabilidade com explicação (por exemplo, "85% de chance de fraude devido aos fatores X e Y")?
   - **Mecanismo de Feedback:** desenho da interface para que o usuário reporte erros do modelo (por exemplo, botão "isso não é uma fraude"), criando o ciclo de *feedback loop* necessário para re-treino futuro.

3. **Perspectiva de Dados (Data Management)**

   Especifica a engenharia necessária para alimentar o modelo em produção.

   - **Pipeline de Ingestão:** definição se os dados serão processados em *batch* (D-1) ou *streaming* (tempo real).
   - **Estratégia de Versionamento:** como garantir a reprodutibilidade? (Por exemplo, uso de ferramentas como DVC ou MLflow para vincular a versão do *dataset* ao modelo treinado).
   - **Política de Privacidade:** implementação técnica das restrições identificadas na fase de *compliance* (por exemplo, anonimização de CPF antes de entrar no *feature store*).

4. **Perspectiva do Modelo (Learning Model)**

   Detalha o ciclo de vida do algoritmo fora do notebook de experimentação.

- **Seleção Definitiva:** escolha da arquitetura final baseada no trade-off entre performance e custo de inferência (por exemplo, escolher uma Random Forest leve em vez de *deep learning* pesado se a diferença de acurácia for marginal).
- **Estratégia de Re-treino:** o modelo será estático ou dinâmico? Qual o gatilho para nova aprendizagem? (Por exemplo, "re-treinar a cada 3 meses"ou "re-treinar se a acurácia cair abaixo de 80%".)

5. **Perspectiva de Infraestrutura (Infrastructure)**

   Dimensiona os recursos computacionais (FinOps).

   - **Ambiente de Inferência:** onde o modelo rodará? (Nuvem pública, datacenter *on-premise* do Estado ou na borda/*edge*).
   - **Requisitos de Hardware:** necessidade de GPU para inferência ou apenas CPU? Memória RAM necessária para carregar o modelo?
   - **Integração:** desenho da API (REST/gRPC) e contratos de dados (*schemas*) para conexão com os sistemas legados do órgão demandante.

Integração entre Viabilidade e Concepção

Embora distintas do ponto de vista conceitual, as atividades de **Viabilidade** e **Concepção** são realizadas de forma integrada e iterativa ao longo da Fase II, com a Viabilidade exercendo um papel orientador sobre a Concepção. Evidências obtidas a partir da análise de dados, da avaliação de riscos e das restrições técnicas informam diretamente o refinamento do caso de uso e das decisões conceituais.

Ao mesmo tempo, ajustes realizados na Concepção — como a redefinição do escopo, dos objetivos ou dos requisitos — podem demandar novas análises de viabilidade, caracterizando ciclos curtos de realimentação. Essa dinâmica reflete os princípios do Lean R&D, promovendo aprendizado incremental, tomada de decisão baseada em evidências e redução progressiva de riscos antes do desenvolvimento do MVP.

Critérios de saída da fase

A Fase II é considerada concluída quando:

- A viabilidade técnica, científica e operacional da solução foi demonstrada por meio de evidências documentadas;
- Os principais riscos associados a dados, modelagem e operação foram identificados e avaliados;

- O caso de uso de IA foi definido e refinado com base nas evidências de viabilidade;
- As métricas técnicas e de impacto público estão claramente estabelecidas;
- O plano de desenvolvimento do MVP foi aprovado pela coordenação da Fábrica de IA, caracterizando uma decisão explícita de avanço no processo.

Etapas do workflow de ML envolvidas

A Fase II de Viabilidade e Concepção atua diretamente sobre etapas iniciais e estruturantes do workflow de Machine Learning, conforme caracterizado em estudos empíricos sobre sistemas de ML em produção, especialmente o workflow em nove estágios descrito por Amershi et al.[1]. Nessa fase, não há ainda treinamento sistemático de modelos em ambiente produtivo, mas são estabelecidas as bases técnicas, conceituais e organizacionais que condicionam todas as etapas subsequentes do ciclo de vida do sistema de IA.

Em particular, destacam-se as seguintes etapas do workflow de ML:

- **Definição dos requisitos do modelo (Model Requirements):** durante a Fase II, são explicitados os objetivos do modelo de ML, os tipos de decisões que deverão ser apoiadas ou automatizadas e os critérios iniciais de sucesso. Conforme observado por Amershi et al.[1], decisões equivocadas ou vagas nessa etapa tendem a gerar retrabalho significativo nas fases de experimentação e avaliação. A análise de viabilidade fornece evidências que ajudam a restringir o espaço de soluções possíveis, enquanto a concepção formaliza requisitos funcionais e não funcionais do modelo.
- **Coleta de Dados (Data Collection):** a coleta de dados é abordada de forma analítica e exploratória, com foco na identificação das fontes disponíveis ou potenciais, internas ou externas ao órgão. Essa atividade inclui a avaliação da acessibilidade, cobertura temporal, atualidade e governança dos dados. Estudos empíricos indicam que a descoberta e a gestão de dados representam um dos principais fatores de risco em projetos de ML, exigindo atenção antecipada [1].
- **Limpeza e Preparação de Dados (Data Cleaning and Preparation):** ainda que a preparação sistemática de dados ocorra com maior intensidade em fases posteriores, nesta fase são realizadas análises iniciais de qualidade, consistência e completude dos dados. Essas análises permitem identificar ruídos, inconsistências e limitações estruturais que impactam diretamente a viabilidade técnica da solução e orientam decisões sobre escopo e complexidade.
- **Rotulagem de Dados (Data Labeling), quando aplicável:** quando o problema requer aprendizado supervisionado, a Fase II considera a necessidade, o custo e a viabilidade do processo de rotulagem. Conforme discutido por Amershi et al.[1], a rotulagem é frequentemente uma das atividades mais custosas e demoradas do workflow de ML, podendo envolver especialistas

de domínio ou estratégias de rotulagem semi-automática. A avaliação antecipada dessa etapa é fundamental para evitar atrasos e inviabilização do projeto.

- **Análise de ciclos de realimentação e riscos sistêmicos:** mesmo nas etapas iniciais do workflow, a Fase II considera a natureza não linear do desenvolvimento de sistemas de ML, marcada por ciclos frequentes de realimentação entre dados, modelagem e avaliação. Amershi et al.[1] destacam que fenômenos como acoplamento entre componentes (*entanglement*), mudanças na distribuição dos dados e comportamento não monotônico de erros devem ser antecipados desde as fases iniciais, influenciando decisões de viabilidade e concepção.

De forma geral, a Fase II posiciona-se como um ponto de ancoragem do workflow de ML, garantindo que atividades posteriores de engenharia de atributos, treinamento, avaliação, implantação e monitoramento sejam conduzidas sobre bases sólidas, reduzindo riscos técnicos, científicos e organizacionais.

2.3 Fase III – Desenvolvimento de MVP

Nesta fase, transformamos os notebooks experimentais em ativos de produção. O processo envolve a refatoração completa do código, o desenvolvimento final do modelo com validação cruzada, e sua integração a uma solução de software preparada para o mundo real. O objetivo é mitigar o risco de operacionalização, garantindo que a solução não seja apenas um modelo estatístico funcional, mas uma aplicação de software segura, testável e manutenível.

Seguindo o alerta de Sculley et al. [7] sobre o débito técnico oculto, reconhecemos que o código do modelo de ML representa apenas uma pequena fração da solução. A maior parte do esforço de engenharia nesta fase concentra-se na infraestrutura de suporte: coleta de dados, verificação, gestão de recursos e monitoramento.

Objetivos da fase

- **Produtização:** refatorar o código experimental (geralmente notebooks desestruturados) para padrões de engenharia de software (modularização, orientação a objetos).
- **Automação de Dados:** substituir extrações manuais (CSVs estáticos) por pipelines de dados automatizados e resilientes.
- **Garantia de Qualidade (QA):** implementar testes automatizados não apenas para o código, mas para os dados e para o modelo.

Fluxo de Atividades

1. **Engenharia de Dados (construção do pipeline):** com base na Perspectiva de Dados definida no PerSpecML (Fase II), a equipe de Engenharia de Dados implementa:
   - **ETL automatizado:** scripts que extraem dados das fontes governamentais, transformam e carregam no ambiente de modelo de forma agendada (por exemplo, via Airflow ou *cron*).
   - **Validação de dados (*data testing*):** implementação de travas de segurança na entrada. Se o dado chegar com formato errado ou valores inválidos (por exemplo, idade negativa), o pipeline deve falhar de forma controlada e alertar a equipe, impedindo que o modelo seja alimentado com dados incorretos (*garbage in, garbage out*).
2. **Engenharia de Machine Learning (empacotamento):** o Cientista de Dados e o Engenheiro de ML trabalham juntos para:
   - **Refatoração do modelo:** conversão do código de treinamento em classes/funções reutilizáveis.
   - **Registro de modelo (*model registry*):** salvamento do artefato treinado (arquivo binário do modelo) com versionamento estrito, vinculando-o ao *dataset* exato que o gerou.
   - **Containerização:** criação da imagem (por exemplo, Docker) que contém o modelo e todas as dependências, garantindo que ele rode de forma idêntica no servidor do Estado e no ambiente de desenvolvimento.
3. **Desenvolvimento da aplicação e integração:** a equipe de Desenvolvimento (backend/frontend) constrói a "casca"do sistema:
   - **Exposição via API:** criação de endpoints (REST/gRPC) para que outros sistemas do governo possam consultar o modelo.
   - **Interface do Usuário (UI):** implementação do frontend validado nos mockups da Fase II, incluindo as explicações das decisões da IA.
   - **Implementação de *fallbacks*:** definição do comportamento do sistema caso o modelo demore a responder ou esteja indisponível (por exemplo, exibir uma regra de negócio padrão).
4. **Bateria de testes multidimensionais:** diferentemente do software tradicional, testam-se três dimensões [1]:
   - **Testes de código:** testes unitários nas funções de pré-processamento.
   - **Testes de dados:** verificação de esquema e distribuição estatística.
   - **Testes de modelo:** verificação de invariância (por exemplo, o modelo muda a resposta se mudarmos apenas o nome da pessoa?) e testes de carga (por exemplo, o modelo suporta 100 requisições por segundo?).

Questões-chave respondidas

Antes de avançar para a validação com usuários, a equipe técnica deve assegurar que o MVP fornece respostas afirmativas para três perguntas fundamentais, consolidando a qualidade da engenharia:

- **O modelo atende aos requisitos mínimos definidos?** Verifica se as métricas de sucesso estabelecidas na fase de Concepção, como precisão ou recall, foram atingidas com os dados de produção.
- **O desempenho técnico é aceitável?** Confirma se os requisitos não funcionais, como tempo de latência na inferência e consumo de recursos computacionais, estão dentro dos limites.
- **A solução pode ser integrada aos sistemas existentes?** Garante que as APIs e conexões de dados conversam fluidamente com o legado do órgão, sem exigir ajustes manuais.

Artefatos de saída

Ao final da Fase III, entrega-se o MVP instalado em ambiente de Homologação:

- Repositório de código-fonte documentado com com CI/CD configurado;
- Pipeline de dados implementado e versionado;
- Conjunto de dados preparado e documentado;
- Modelo de IA treinado (versão MVP);
- Relatório de avaliação offline do modelo;
- Protótipo funcional (API, serviço ou aplicação).

Etapas do workflow de ML envolvidas

- Engenharia de Atributos
- Treinamento do Modelo
- Avaliação do Modelo

2.4 Fase IV – Piloto Controlado

A Fase de Piloto representa a transição do sistema para um ambiente de operação controlada, com uso real e escopo limitado. Diferentemente dos testes tradicionais de software, que se concentram predominantemente na identificação de defeitos de implementação, o piloto em sistemas de IA tem como foco a validação do comportamento do modelo frente a dados reais de produção, caracterizados por maior variabilidade, ruído e possíveis desvios em relação aos dados utilizados no treinamento.

O objetivo central não é apenas técnico, incorporando também dimensões organizacionais e culturais. Busca-se avaliar se a solução entrega valor concreto aos servidores públicos, se apoia adequadamente a tomada de decisão e se os mecanismos de supervisão humana (*human-in-the-loop*) operam de forma eficaz, garantindo segurança, transparência e alinhamento ético durante o uso em contexto real.

Objetivos da fase

- **Validação de generalização:** confirmar se a performance técnica se mantém estável quando exposta a ruídos e padrões inéditos do ambiente de produção.
- **Aferição de valor público:** mensurar, com usuários reais, se o sistema resolve a dor original (por exemplo, reduziu a fila? melhorou a triagem?) antes de investir na escala total.
- **Ajuste de interação:** refinar a interface e a experiência do usuário (UX) com base em feedbacks qualitativos.

Seleção da estratégia de validação

A estratégia de implantação deve ser selecionada durante o planejamento da fase, considerando o nível de risco (PL 2338/2023) e a autonomia do sistema [2]. As abordagens recomendadas incluem:

- **Abordagem A: Grupo Focal (restrição de escopo)**
  - **Cenário ideal:** chatbots, sistemas de recomendação ou novas ferramentas sem processo anterior.
  - **Descrição:** o sistema é liberado com funcionalidade total, mas apenas para um grupo restrito de usuários (por exemplo, 5% dos servidores ou apenas uma unidade específica).
  - **Foco:** coleta intensa de feedback qualitativo e monitoramento de erros de borda.
- **Abordagem B: Operação em paralelo (*shadow mode*)**
  - **Cenário ideal:** sistemas de alto risco, classificadores automáticos ou substituição de processos manuais críticos.

  - **Descrição:** o modelo processa os dados reais em tempo real, mas suas decisões não são exibidas ao usuário final; elas são registradas para comparação posterior com a decisão humana.
  - **Foco:** segurança total, permitindo validar a acurácia sem risco de impacto negativo no serviço público.

- **Abordagem C: Operação assistida (*human-in-the-loop*)**
  - **Cenário ideal:** apoio à tomada de decisão (por exemplo, triagem fiscal, diagnósticos).
  - **Descrição:** a IA atua como uma "segunda opinião". O sistema sugere uma decisão (por exemplo, "Probabilidade de fraude: 85%"), mas a ação final exige confirmação humana.
  - **Foco:** produtividade e confiança; o usuário valida a IA caso a caso, gerando dados de correção para re-treino.

Atividades de monitoramento

Independentemente da estratégia escolhida, a equipe técnica deve monitorar três dimensões:

- **Métricas de sistema:** latência, erros de disponibilidade e consumo de recursos.
- **Estabilidade do modelo (drift):** monitoramento estatístico para detectar se a distribuição dos dados de entrada mudou drasticamente em relação ao treino.
- **Indicadores de negócio:** impacto real na operação (por exemplo, tempo médio de atendimento).

Artefatos de saída (deliverables)

- **Relatório de Validação de Campo:** análise comparativa entre o esperado (design) e o realizado (realidade).
- **Dataset de Curadoria ("Golden Set"):** conjunto de dados reais processados durante o piloto, rotulados ou corrigidos pelos usuários, que servirá de base para futuros re-treinos.
- **Parecer de Ajuste Ético:** avaliação se as salvaguardas desenhadas para cumprir o PL 2338/2023 foram eficazes na prática [2].

Questões-chave respondidas

Para ser autorizada a mudança para a próxima fase, deve-se responder:

- **A solução gera valor real?** O KPI de negócio melhorou ou a ferramenta foi ignorada pelos usuários?
- **O modelo é robusto?** Houve degradação de performance ou "alucinações"graves com dados reais?
- **A estratégia de supervisão é adequada?** O humano consegue intervir quando a IA falha?

Critérios de saída da fase

- Impacto positivo comprovado;
- Estabilidade técnica validada;
- Recomendação formal para escala.

Etapas do workflow de ML envolvidas

- Implantação do Modelo
- Monitoramento Inicial
- Realimentação para etapas anteriores

2.5 Fase V – Escala e Operação

Esta fase marca a transição do "modo projeto"(Pesquisa e Desenvolvimento) para o "modo produto"(solução em operação). Contudo, é vital distinguir as responsabilidades: cabe à Fábrica de IA garantir a sustentabilidade técnica (engenharia, estabilidade e monitoramento), enquanto a execução da implantação no ambiente de produção e a gestão da política pública são atribuições exclusivas do Órgão Demandante.

Desta forma, esta fase foca na preparação dos artefatos de software e documentação, na configuração das rotinas de MLOps e na Transferência Tecnológica, garantindo que a TI do parceiro tenha autonomia para assumir o sistema.

Objetivos da fase

- **Habilitação Técnica para Escala:** fornecer os artefatos de software, containers e manuais de infraestrutura necessários para que a equipe de TI do órgão demandante realize o deploy seguro no ambiente de produção oficial.

- **Observabilidade total:** entregar o sistema com rotinas de monitoramento e métricas para identificação de desvios configuradas, permitindo que a degradação do modelo (*model decay*) seja detectada pelos operadores.
- **Transferência de conhecimento:** capacitar a equipe técnica e de negócios do parceiro para operar, auditar e manter a solução, concretizando o encerramento do ciclo de desenvolvimento.

Fluxo de Atividades

1. **Preparação do pacote de liberação:** a Fábrica não acessa a produção diretamente. Em vez disso, gera artefatos auditáveis para a TI do órgão:
   - **Empacotamento:** geração das imagens finais de container (por exemplo, Docker) e dos arquivos de configuração (IaC — *Infrastructure as Code*).
   - **Homologação de arquitetura:** validação conjunta com a TI do órgão para garantir que o ambiente de destino atende aos requisitos de hardware (GPU/memória) definidos na Concepção.
2. **Suporte:** durante a janela de implantação executada pelo órgão demandante, a Fábrica atua como suporte especializado, provendo:
   - recomendações de métodos seguros de liberação, e orientando a equipe do órgão sobre os procedimentos de reversão (rollback) caso ocorra alguma falha crítica.
   - verificação técnica se o modelo instalado em produção está reproduzindo os resultados do ambiente de homologação.
3. **Operação assistida:** nos primeiros meses, estabelece-se um regime de transição:
   - **TI do órgão:** assume a administração do ambiente, gestão de acessos e primeiro nível de suporte.
   - **Fábrica de IA:** atua apenas sob chamado para investigar anomalias complexas no comportamento do modelo (*model drift*) ou bugs de código profundo.
4. **Transferência tecnológica e capacitação:** atividade mandatória para o encerramento do projeto:
   - **Workshop de "passagem de bastão":** treinamento prático com os administradores de sistema do órgão sobre os scripts de manutenção e re-treino.
   - **Letramento para gestores:** explicação final sobre as limitações do modelo e a interpretação dos painéis de monitoramento.
   - **Entrega de documentação:** repasse formal dos repositórios, documentação de API e relatórios de impacto (AIA).

Artefatos de saída

- **Pacote de Instalação (*release package*):** imagens, binários e scripts de infraestrutura validados.
- **Kit de Transferência Tecnológica:** conjunto consolidado de ativos que garante a independência técnica do órgão demandante:
  - **Repositório de código-fonte:** acesso completo ao versionamento do projeto (Git), contendo não apenas o modelo final, mas todo o histórico de desenvolvimento, scripts de treinamento e arquivos de configuração de infraestrutura (*Infrastructure as Code*).
  - **Manuais de operação:** documentação técnica detalhando os procedimentos de rotina (por exemplo, como reiniciar o serviço e como atualizar variáveis de ambiente) e um guia prático para diagnóstico e correção de falhas comuns.
  - **Matriz de monitoramento e observabilidade:** definição dos indicadores que a equipe de TI deve acompanhar no painel de controle, distinguindo alertas de infraestrutura de alertas de degradação do modelo (por exemplo, mudança no perfil dos dados de entrada ou queda na taxa de acerto).
- **Termo de Transferência de Tecnologia:** documento em que a Fábrica atesta a entrega e o órgão demandante aceita a responsabilidade pela operação.

Questões-chave respondidas

Antes de formalizar o encerramento do ciclo de desenvolvimento, a equipe da Fábrica e o Órgão Demandante devem ter clareza sobre três pontos que garantem a longevidade do projeto:

- **A solução suporta tecnicamente a operação em larga escala?** Deve-se verificar se a infraestrutura foi dimensionada corretamente e se os testes de carga comprovaram que o sistema manterá a estabilidade sob o volume de requisições previsto para o uso massivo.
- **Os mecanismos de monitoramento contínuo e evolução estão ativos?** É necessário confirmar se o monitoramento implantado reporta a saúde do servidor e alerta sobre a degradação da inteligência do modelo, assegurando a existência de um plano claro para o re-treinamento futuro.
- **A governança e a propriedade do sistema foram formalizadas?** Esta questão assegura que os papéis de responsabilidade estão definidos, estabelecendo quem responde legalmente pelo uso da IA e quem detém o conhecimento técnico para mantê-la, evitando o vácuo de gestão após a entrega.

Critérios de saída da fase

- Solução operacionalizada;
- Governança estabelecida;
- Encerramento formal do projeto.

Etapas do workflow de ML envolvidas

- Monitoramento do Modelo
- Aprendizado Contínuo
- Re-treinamento periódico

Capítulo 3

Perfis Técnicos Envolvidos

Este capítulo define os perfis técnicos que compõem a Fábrica de IA, estabelecendo suas principais responsabilidades, competências, domínios técnicos de atuação e fronteiras de decisão ao longo do ciclo de vida das soluções desenvolvidas pela Fábrica de IA. O texto explicita como esses perfis se articulam com as etapas do workflow de Machine Learning e com as fases do processo da Fábrica de IA, assegurando coerência entre concepção, desenvolvimento, implantação e operação das soluções. Dessa forma, fornece uma base comum para a organização do trabalho técnico, a composição de equipes multidisciplinares e a coordenação das atividades ao longo das diferentes fases do processo.

O capítulo abrange todo o ciclo de vida das soluções de Inteligência Artificial desenvolvidas no âmbito da Fábrica de IA, desde a exploração inicial do problema público até a operação contínua em escala institucional, contemplando os principais aspectos técnicos e organizacionais necessários à sua sustentação. Parte-se da premissa de que os perfis técnicos definidos são complementares e interdependentes, não devendo ser compreendidos como silos funcionais. Suas responsabilidades se articulam e se reconfiguram conforme a fase do processo, a complexidade do problema tratado e o nível de maturidade da solução.

Assume-se, ainda, a natureza socio-técnica das soluções de IA no setor público, reconhecendo que decisões técnicas estão associadas a aspectos legais, éticos e institucionais. Nesse sentido, os perfis técnicos devem atuar em consonância com princípios de governança, transparência, segurança da informação e conformidade regulatória, tendo como premissa central a entrega sustentável de valor público.

3.1 Perfis Técnicos Envolvidos

O desenvolvimento de soluções de Inteligência Artificial no contexto da Fábrica de IA exige a atuação coordenada de perfis técnicos especializados, cujas responsabilidades refletem as particularidades de sistemas intensivos em dados, modelos estatísticos e integração com ambientes organizacionais complexos do setor público. Diferentemente do desenvolvimento de software tradicional, soluções de IA apresentam elevada incerteza técnica, forte dependência de dados e comportamento dinâmico ao longo do tempo [1, 7].

Nesse contexto, a Fábrica de IA estrutura sua atuação técnica a partir de três perfis centrais: **Engenheiro de Dados**, **Engenheiro de Machine Learning** e **Engenheiro de Software**. Esses perfis operam de forma isolada, mas de maneira integrada ao longo das fases do processo, com responsabilidades predominantes que evoluem conforme a maturidade da solução e as etapas do workflow de Machine Learning envolvidas.

3.1.1 Engenheiro de Dados

Responsabilidade central: garantir a disponibilidade, a qualidade, a governança, a rastreabilidade e a confiabilidade dos dados utilizados ao longo de todo o ciclo de vida da solução de IA.

O Engenheiro de Dados desempenha papel estruturante em projetos de IA, uma vez que os dados constituem simultaneamente o principal insumo técnico e uma das maiores fontes de risco organizacional, legal e operacional. Sua atuação busca reduzir incertezas relacionadas à origem, qualidade, atualização, integração e conformidade legal dos dados, criando bases sólidas para a experimentação científica, para o treinamento de modelos e para a operação segura da solução em ambientes institucionais.

Além disso, esse perfil é responsável por viabilizar a reprodutibilidade dos experimentos e a auditabilidade das decisões automatizadas, aspectos críticos no contexto do setor público.

Competências e domínios técnicos

- Integração e consolidação de bases de dados governamentais heterogêneas, estruturadas, semi-estruturadas e não estruturadas;
- Projeto e implementação de pipelines de ingestão, ETL/ELT e versionamento de dados;
- Modelagem lógica e física de dados para suporte a análises exploratórias, treinamento e inferência;
- Tratamento de dados em processamento em lote e, quando aplicável, em streaming;

- Gestão de data lakes, data warehouses e arquiteturas do tipo lakehouse;
- Implementação de mecanismos de versionamento, linhagem (*data lineage*) e auditoria de dados;
- Definição e aplicação de práticas de governança de dados, segurança da informação e conformidade com a LGPD.

Atuação predominante no processo

- **Fase I – Exploração**: análise preliminar de disponibilidade, acessibilidade, qualidade e riscos associados aos dados;
- **Fase II – Viabilidade e Concepção**: análises exploratórias, avaliação de riscos e definição da arquitetura de dados;
- **Fase III – Desenvolvimento de MVP**: implementação de pipelines reprodutíveis e datasets versionados.

Conhecimentos e ferramentas típicas

- Engenharia de dados, bancos de dados relacionais e não relacionais;
- ETL/ELT, processamento distribuído e orquestração de pipelines;
- Data lakes, lakehouses e catálogos de dados;
- Versionamento e linhagem de dados;
- Ferramentas e tecnologias: SQL, Python, Apache Spark, Airflow, Kafka, DVC, Delta Lake.

3.1.2 Engenheiro de Machine Learning

Responsabilidade central: conceber, desenvolver, avaliar, implantar e manter modelos de Machine Learning adequados ao problema público, assegurando rigor metodológico, desempenho técnico, explicabilidade e sustentabilidade ao longo do tempo.

O Engenheiro de Machine Learning atua na interseção entre ciência de dados, estatística e engenharia, sendo responsável por transformar dados preparados em modelos capazes de apoiar ou automatizar decisões. Esse perfil reconhece explicitamente a natureza experimental dos sistemas de ML e os riscos associados a vieses, degradação de desempenho, mudanças de contexto e impactos indesejados.

No contexto da Fábrica de IA, assume papel central na definição e operação das práticas de **MLOps**, garantindo que modelos sejam desenvolvidos, avaliados e operados de forma controlada, rastreável e alinhada às diretrizes institucionais.

Competências e domínios técnicos

- Fundamentos de estatística, aprendizado de máquina e avaliação experimental;
- Engenharia e seleção de atributos, feature stores e métricas de desempenho;
- Seleção, treinamento e ajuste de algoritmos supervisionados, não supervisionados e auto-supervisionados;
- Avaliação de qualidade, risco, viés e impacto dos modelos;
- Implementação de práticas de MLOps, incluindo versionamento, experimentação e model registry;
- Monitoramento de desempenho, detecção de drift de dados e de conceito.

Atuação predominante no processo

- **Fase II – Viabilidade e Concepção**: definição de requisitos do modelo, métricas e riscos científicos;
- **Fase III – Desenvolvimento de MVP**: treinamento, avaliação offline e refinamento dos modelos;
- **Fase IV – Piloto Controlado**: monitoramento inicial e ajustes iterativos;
- **Fase V – Escala e Operação**: re-treinamento, evolução contínua e governança dos modelos.

Conhecimentos e ferramentas típicas

- Python e bibliotecas de ML;
- Frameworks de treinamento e avaliação;
- Ferramentas de MLOps e model registry;
- Plataformas de experimentação e deploy de modelos;
- Ferramentas e tecnologias: scikit-learn, PyTorch, TensorFlow, MLflow, ferramentas de feature store.

3.1.3 Engenheiro de Software

Responsabilidade central: transformar modelos de IA em soluções de software robustas, utilizáveis, escaláveis, seguras e integráveis ao ecossistema tecnológico do governo.

O Engenheiro de Software é responsável por operacionalizar os artefatos produzidos pelas atividades de dados e Machine Learning, garantindo que modelos sejam disponibilizados como serviços confiáveis e mantenham padrões adequados de qualidade, segurança, observabilidade e manutenção.

Esse perfil atua fortemente na integração entre **DevOps** e **MLOps**, assegurando que a infraestrutura e o software de suporte estejam alinhados às necessidades específicas de sistemas baseados em IA.

Competências e domínios técnicos

- Engenharia de software, arquitetura de sistemas e padrões de projeto;
- Desenvolvimento de APIs e serviços orientados a dados e modelos;
- Integração com sistemas legados e infraestruturas institucionais;
- Conteinerização, orquestração e automação de infraestrutura;
- DevOps, CI/CD, observabilidade e segurança de aplicações.

Atuação predominante no processo

- **Fase III – Desenvolvimento de MVP**: desenvolvimento do protótipo funcional (API/serviço/aplicação);
- **Fase IV – Piloto Controlado**: integração institucional; garantia de estabilidade, desempenho e observabilidade;
- **Fase V – Escala e Operação**: operação em produção; automação de pipelines; sustentação e evolução contínua.

Conhecimentos e ferramentas típicas

- Linguagens e frameworks de backend e integração;
- Arquiteturas de microserviços e APIs;
- Docker, Kubernetes e automação de infraestrutura;
- Ferramentas de CI/CD, monitoramento e logging;
- Ferramentas e tecnologias: Java/Python, frameworks web, Git, Docker, Kubernetes.

3.2 Alinhamento com o Workflow de Machine Learning

Etapas críticas

- Definição de requisitos do modelo
- Dados (coleta, preparação e rotulagem)
- Modelagem (engenharia de atributos, treinamento e avaliação)
- Implantação
- Monitoramento e aprendizado contínuo

Distribuição de protagonismo

- Engenheiro de Dados → domínio dos dados e sua governança
- Engenheiro de Machine Learning → domínio da modelagem e do ciclo de vida do modelo
- Engenheiro de Software → domínio da operacionalização e da integração sistêmica

3.3 Alinhamento com o Processo da Fábrica de IA

Fase I – Exploração

- Dados: viabilidade, riscos e limitações iniciais
- ML: definição preliminar do problema e métricas
- Software: apoio conceitual e análise de integração

Fase II – Viabilidade e Concepção

- Dados: EDA, qualidade, governança e arquitetura
- ML: adequação metodológica e riscos científicos
- Software: definição da arquitetura conceitual

Fase III – Desenvolvimento de MVP

- Dados: pipelines reprodutíveis e datasets versionados
- ML: modelos treinados, avaliados e documentados
- Software: protótipo funcional (API/serviço)

Fase IV – Piloto Controlado

- Dados: suporte ao monitoramento e coleta operacional
- ML: avaliação em ambiente real e ajustes
- Software: integração e estabilidade

Fase V – Escala e Operação

- Dados: dados operacionais, atualização e governança contínua
- ML: re-treinamento, monitoramento e evolução dos modelos
- Software: operação institucional, segurança e governança

3.4 Síntese de atuação por perfil e fase

Perfil Técnico	Domínios Técnicos Principais	Fase I – Exploração	Fase II – Viabilidade e Concepção	Fase III – Desenvolvimento de MVP	Fase IV – Piloto Controlado	Fase V – Escala e Operação
Engenheiro de Dados	Engenharia de dados; integração de bases governamentais; ETL/ELT; data lakes/lakehouse; governança, qualidade, versionamento e linhagem de dados; segurança e LGPD	Avaliação de disponibilidade, acessibilidade, qualidade e riscos dos dados	Análise exploratória (EDA); definição da arquitetura de dados; avaliação de riscos técnicos e legais	Implementação de pipelines reprodutíveis; datasets preparados, versionados e documentados	Suporte à coleta e qualidade de dados operacionais; apoio ao monitoramento	Gestão de dados operacionais; atualização contínua; governança e rastreabilidade
Engenheiro de Machine Learning	Estatística e ML; engenharia de atributos; seleção e avaliação de modelos; métricas; explicabilidade; MLOps (experimentação, versionamento, model registry, monitoramento)	Apoio conceitual na definição preliminar do problema e viabilidade analítica	Definição de requisitos do modelo; métricas técnicas; riscos científicos e metodológicos	Treinamento, avaliação offline, comparação e refinamento de modelos	Monitoramento inicial em ambiente real; ajustes iterativos; análise de impacto	Re-treinamento; aprendizado contínuo; governança e evolução dos modelos
Engenheiro de Software	Engenharia de software; arquitetura de sistemas; APIs e microserviços; integração com sistemas legados; DevOps; CI/CD; observabilidade; segurança	Análise conceitual de integração e restrições tecnológicas	Definição da arquitetura de software e requisitos não funcionais	Desenvolvimento do protótipo funcional (API/serviço/aplicação)	Integração institucional; garantia de estabilidade, desempenho e observabilidade	Operação em produção; automação de pipelines; sustentação e evolução contínua

Tabela 3.1: Síntese dos perfis técnicos e sua atuação predominante por fase do processo da Fábrica de IA.

Apêndice A

Portfólio de Problemas e Oportunidades de IA

A.1 Capa / Identificação

GOVERNO DO ESTADO DO PIAUÍ
FÁBRICA DE INTELIGÊNCIA ARTIFICIAL

PORTFÓLIO DE PROBLEMAS E OPORTUNIDADES DE IA

Mapeamento Estratégico de Demandas

Órgão Demandante:	[Inserir Nome da Secretaria/Órgão]
Data do Mapeamento:	[DD/MM/AAAA]
Responsável Técnico:	[Nome do Analista da Fábrica]
Versão do Documento:	1.0

A.2 Contexto e Objetivo do Documento

Este documento consolida o levantamento exploratório (Fase I - Exploração) realizado pela Fábrica de IA junto ao [**NOME DO ÓRGÃO**]. O objetivo central é transformar "ideias e desejos"em um portfólio estruturado de oportunidades tecnológicas.

Este artefato tem como objetivo servir como um Mapa de Decisão Estratégica. Ele diferencia o que é tecnicamente viável do que é apenas especulação, aplicando critérios de engenharia de dados e conformidade ética (PL 2338/2023) para assegurar que os recursos públicos sejam investidos apenas em projetos com alto potencial de retorno social.

A.2.1 Como utilizar este documento

Este portfólio pode ser utilizado pela gestão do órgão demandante para:

1. **Priorizar Investimentos:** Escolher qual problema atacar primeiro com base em dados técnicos.
2. **Justificar Orçamento:** Embasar solicitações de recursos para desenvolvimento tecnológico.
3. **Alinhar Expectativas:** Compreender as limitações e pré-requisitos (dados) de cada ideia.

A.3 Mapeamento de Dores e Oportunidades

Nesta seção, registramos a visão do negócio. O foco não é a tecnologia em si, mas o problema que afeta o serviço público.

Instruções de Preenchimento

Orientação para o Mapeamento:

- ***Foco na "Dor"(Pain Point):*** *Evite descrever a solução (ex: "Quero um Chatbot"). Descreva o problema (ex: "Meus atendentes gastam 70% do tempo respondendo a mesma pergunta sobre datas de inscrição").*
- ***Benefício Esperado (Valor Público):*** *Tente quantificar o impacto. O projeto visa economizar dinheiro, reduzir tempo de espera ou salvar vidas?*
- ***Abrangência:*** *Liste todas as demandas levantadas nas entrevistas, mesmo as que pareçam simples. A triagem técnica será feita na próxima seção.*

ID	Área / Processo	A "Dor"(Problema Real)	Benefício Esperado
01	Ex: Fiscalização	A triagem manual de processos fiscais é lenta e propensa a erros humanos.	Reduzir a evasão fiscal e aumentar a velocidade de auditoria em 50%.
02	[Inserir Área]	[Descrever o gargalo atual sem citar a solução]	[Qual o impacto para o cidadão?]
03	[Inserir Área]	[Descrever o gargalo atual]	[Qual o impacto para o cidadão?]

A.4 Análise de Viabilidade e Triagem Técnica

Aqui, a Fábrica de IA aplica o filtro da engenharia e da ética. O objetivo é informar se a demanda é tecnicamente possível, se existem dados para alimentá-la e se ela é segura.

Instruções de Preenchimento

Critérios de Avaliação Técnica:

1. ***Técnica:*** *Classifica a natureza da solução.*
   - *IA (Preditiva/Generativa): Necessário quando há padrões complexos não lineares.*
   - *Automação Tradicional (RPA/Software): Preferível quando o problema pode ser resolvido com regras fixas (Se/Então). É mais barato e explicável.*
2. ***Disponibilidade de Dados:*** *A IA aprende com exemplos.*
   - *Alta: Dados digitais, estruturados (Banco de Dados, CSV), centralizados e com histórico confiável. Pronto para Modelagem.*
   - *Média (Desestruturada): Dados digitais existem, mas estão em formatos difíceis (PDFs digitalizados, imagens, campos de texto livre). Requer Engenharia de Dados (OCR/PLN) antes.*
   - *Fragmentada (Silos): Dados estruturados existem, mas estão espalhados em sistemas diferentes que não conversam entre si. Requer Integração de Bases antes.*
   - *Baixa/Inexistente: Dados em papel, formulários físicos ou processo nunca mensurado. Inviável a curto prazo (Requer Digitalização).*
3. ***Risco Ético (PL 2338/2023):*** *Utiliza-se o Framework de Autoavaliação de Impacto Ético (AIE) do Governo Federal para classificar o risco regulatório [3]:*
   - *Baixo: Tarefas administrativas sem impacto direto em direitos.*
   - *Alto: Saúde, segurança, crédito, educação. Exige supervisão humana.*
   - *Excessivo: Exploração de vulnerabilidade ou discriminação. Veto jurídico.*

ID	Solução Hipotética	Técnica	Dados	Risco	Parecer Técnico
01	Classificador de Risco	IA Preditiva	Alta	Alto	**VIÁVEL**. A solução é possível, mas requer supervisão humana (Human-in-the-loop).
02	Chatbot de Atendimento	IA Generativa	Média	Baixo	**VIÁVEL C/ RESTRIÇÃO**. Necessário higienizar base de conhecimento antes.
03	Planilha Automatizada	RPA / Excel	Alta	Baixo	**TRANSFERIR**. Não requer IA. Encaminhar para desenvolvimento tradicional.
04	Análise de Emoções	Visão Comp.	Alta	Excessivo	**INVIÁVEL**. Risco ético proibitivo (Veto Legal Art. 14).

A.5 Matriz de Priorização e Subsídios para Decisão

Com base na análise técnica acima, a Fábrica de IA categoriza as oportunidades para auxiliar o gestor na escolha do projeto a ser executado.

Instruções de Preenchimento

*Esta seção cruza a **Complexidade de Implementação** com o **Impacto Esperado**.*

- *Use esta matriz para equilibrar o portfólio. Não escolha apenas projetos complexos (risco de não entregar nada) nem apenas projetos simples (baixo impacto político).*
- *A decisão final de qual projeto executar é do **Gestor do Órgão**, baseada em orçamento e urgência.*

Categoria	Descrição Estratégica	IDs Sugeridos
Vitórias Rápidas *(Quick Wins)*	Projetos de baixo risco técnico e alto valor percebido a curto prazo. Ideais para gerar confiança inicial e resultados rápidos (3-6 meses).	Ex: ID 03, ID 05
Apostas Estratégicas	Projetos transformadores. Exigem maior tempo de desenvolvimento e investimento, mas resolvem problemas estruturais do Estado.	Ex: ID 01
Projetos Estruturantes *(Enablers)*	Iniciativas necessárias para "arrumar a casa"(Digitalização, Data Lake). Não entregam IA final, mas viabilizam o futuro.	Ex: ID 02
Despriorizados	Projetos onde o custo de desenvolvimento supera o benefício, ou onde a tecnologia atual ainda é imatura/arriscada.	Ex: ID 04

A.6 Validação e Assinaturas

Fábrica de IA	**Gestor do Órgão Demandante**
Product Owner / Cientista Líder	Secretário / Diretor
Data: ____/____/_____	Data: ____/____/_____

Apêndice B

Detalhamento do Problema Priorizado

GOVERNO DO ESTADO DO PIAUÍ
FÁBRICA DE INTELIGÊNCIA ARTIFICIAL

DETALHAMENTO DO PROBLEMA PRIORITÁRIO

Definição de Escopo e Viabilidade (Discovery)

Nome do Projeto:	[Inserir Nome Curto e Descritivo]
Órgão Demandante:	[Inserir Secretaria/Departamento]
ID no Portfólio:	[Ex: OP-2026-001]
Responsável Técnico:	[Analista da Fábrica]
Responsável de Negócio:	[Gestor do Órgão]
Data de Elaboração:	[DD/MM/AAAA]

B.1 Introdução

Este documento consolida o entendimento aprofundado sobre o problema [**NOME DO PROBLEMA**], priorizado durante a Fase de Exploração.

Seu objetivo é apresentar todas as evidências necessárias — incluindo a dor do negócio, a viabilidade dos dados e a análise preliminar de riscos — para fundamentar a decisão do Comitê Gestor sobre a continuidade do projeto. Este artefato **não representa o design da solução**, mas sim a validação de que existe um problema real que merece ser resolvido com Inteligência Artificial.

B.2 1. Contextualização Detalhada do Problema

Instruções de Preenchimento

Descreva o cenário atual em profundidade. Como o processo funciona hoje? Onde exatamente ocorre a falha ou ineficiência? Evite propor soluções neste momento; foque no diagnóstico da "dor".

1.1 Descrição da Situação Atual

[Espaço para descrição narrativa. Exemplo: "O processo de concessão de licenças ambientais hoje é 100% manual. O analista recebe o PDF, lê 50 páginas e preenche um checklist. Devido ao volume de 200 pedidos/mês e equipe de apenas 5 pessoas, cria-se um passivo de 6 meses..."]

1.2 Causas Raiz do Problema

- **Causa 1:** [Ex: Dados não integrados entre sistemas]
- **Causa 2:** [Ex: Volume de trabalho superior à capacidade humana]
- **Causa 3:** [Ex: Regras de negócio subjetivas e variáveis]

B.3 2. Objetivos Pretendidos

Instruções de Preenchimento

O que o órgão espera alcançar se este problema for resolvido? Defina o sucesso em termos de política pública.

Objetivo de Negócio	Indicador Preliminar de Sucesso
Ex: Agilizar a resposta ao cidadão.	Redução do tempo médio de 180 para 30 dias.
Ex: Reduzir desperdício de medicamentos.	Redução de 20% no descarte por validade.

B.4 3. Principais Stakeholders Envolvidos

Instruções de Preenchimento

Mapeie quem são os atores envolvidos. Isso é essencial para entender quem fornecerá os dados e quem será impactado pela IA.

- **Cliente (Demandante):** [Quem paga/pede a conta? Ex: Diretor Financeiro]
- **Usuário Operacional:** [Quem usará a ferramenta no dia a dia? Ex: Auditores]
- **Afetado (Sujeito de Dados):** [Sobre quem a decisão é tomada? Ex: Cidadão requerente]
- **Equipe de TI do Órgão:** [Quem sustentará a ferramenta no futuro?]

B.5 4. Hipótese Inicial de Uso de IA

Instruções de Preenchimento

Nesta etapa, não definimos a arquitetura, mas formulamos uma hipótese sobre como a IA poderia resolver o problema descrito.

Declaração da Hipótese:
*[Exemplo: Acreditamos que o uso de **Processamento de Linguagem Natural (NLP)** para ler os documentos PDF e extrair automaticamente os dados-chave para o checklist auxiliará os analistas a focar apenas nas discrepâncias, reduzindo o tempo de triagem.]*

Por que IA é necessária aqui?
[Justificativa: As regras são complexas demais para automação tradicional ou os dados são não-estruturados (texto/imagem).]

B.6 5. Inventário Preliminar de Dados

Instruções de Preenchimento

A viabilidade do projeto depende da existência de dados. Liste o que foi encontrado durante o Discovery.

Fonte	Formato	Volume Aprox.	Histórico	Titularidade
Sistema X	Banco SQL	1 TB	5 anos	Secretaria de Fazenda
Planilhas	Excel (Manuais)	500 arquivos	2 anos	Departamento de RH
Legado	PDF Digitalizado	Desconhecido	10 anos	Arquivo Público

B.7 6. Análise Inicial de Riscos e Conformidade

Instruções de Preenchimento

Avaliação preliminar para identificar "Showstoppers"(impedimentos legais ou éticos) antes de investir no projeto.

6.1 Dados Pessoais (LGPD)

- O problema exige o tratamento de dados pessoais? ( ) Sim ( ) Não
- Há dados sensíveis (saúde, biometria, política, religião)? ( ) Sim ( ) Não

6.2 Ética e Impacto (PL 2338)

- **Impacto no Cidadão:** A solução pode negar acesso a serviços essenciais (saúde, educação, crédito)?
  [ ] Baixo Impacto *[ ] Alto Impacto (Requer Supervisão Humana)*
- **Grupos Vulneráveis:** A solução afeta crianças, idosos ou grupos minoritários?
  [ ] Não *[ ] Sim (Descrever: _____)*

B.8 Decisão do Comitê Gestor

Com base no detalhamento acima, este projeto está:

[ ] **APROVADO** para iniciar a Fase II (Concepção e Design).
[ ] **REPROVADO** ou devolvido para mais estudos.

Responsável Técnico (Fábrica)	**Gestor do Órgão Demandante**
Validação da Viabilidade	Autorização de Investimento

Apêndice C

Relatório de Viabilidade

C.1 Introdução e Objetivo

O propósito deste documento é subsidiar a decisão de avançar ou não para o desenvolvimento do MVP. Conforme a metodologia da Fábrica de IA, esta avaliação não se restringe apenas aos dados, mas cobre três dimensões essenciais para reduzir riscos de insucesso e desperdício de recursos públicos:

1. **Viabilidade Técnica:** Avaliação de dados e infraestrutura computacional.
2. **Viabilidade Científica:** Adequação metodológica e riscos de modelagem.
3. **Viabilidade Operacional:** Capacidade de integração, uso e manutenção no órgão.

C.2 Dimensão: Viabilidade Técnica

Instruções de Preenchimento

Foco na "matéria-prima"(dados) e no "maquinário"(infraestrutura).

C.2.1 Qualidade e Disponibilidade dos Dados (Resumo EDA)

Baseado no Relatório de Análise Exploratória de Dados anexo.

Instruções de Preenchimento

O Relatório de Análise Exploratória de Dados (EDA) resume a inspeção inicial dos dados realizada com técnicas estatísticas e visuais. O objetivo não é apenas descrever os dados, mas revelar limitações estruturais, padrões inesperados e validar hipóteses que impactam diretamente a viabilidade da modelagem.

O relatório da análise exploratória dos dados deve obrigatoriamente relatar os seguintes aspectos:

- **Qualidade Básica e Integridade:**
  - *Completude:* Qual o percentual de dados faltantes (*missing values*) nas variáveis críticas?
  - *Consistência e Duplicidade:* Existem registros duplicados ou contraditórios (ex: datas de nascimento no futuro)?
  - *Atualidade:* Qual a janela temporal dos dados e sua frequência de atualização?
- **Distribuições e Variabilidade:**
  - *Padrões e Outliers:* Foram identificados valores atípicos severos que distorcem a análise?
  - *Variabilidade:* As variáveis possuem variância informacional suficiente para o aprendizado do algoritmo?
- **Desbalanceamento e Classes Raras:**
  - Existe um forte desbalanceamento na variável alvo (ex: 99% de transações normais e apenas 1% de fraudes)?
  - Há classes raras que exigirão técnicas específicas de amostragem (*oversampling/undersampling*)?
- **Vieses Estruturais e Representatividade:**
  - *Sub-representação:* Os dados históricos sub-representam determinados grupos demográficos, contextos geográficos ou períodos de tempo?
  - *Proxies Inadequados:* As variáveis utilizadas como *proxy* (substitutas) representam fielmente o fenômeno real de interesse do negócio?

Artefatos Complementares de Análise

Para permitir uma inspeção mais profunda por parte dos gestores e especialistas de domínio, este relatório estático pode ser complementado pela entrega de:

- **Dashboards Interativos:** Painéis de visualização (ex: Power BI, Metabase, Streamlit) que permitam filtros dinâmicos e cruzamento de variáveis em tempo real.
- **Notebooks Comentados:** Arquivos de código (Jupyter/RMarkdown) documentados, demonstrando a linhagem do tratamento de dados.

Conclusão da Análise de Dados:
[Espaço para o Cientista de Dados resumir se os dados, no estado atual, suportam a criação do modelo ou se exigirão esforço massivo de engenharia e mitigação de viés.]

C.2.2 Infraestrutura Computacional Necessária

Instruções de Preenchimento

Avalie se existem recursos para processar a solução.

- **Capacidade de Processamento:** [Ex: O treinamento requer GPU dedicada? A inferência roda em CPU padrão?]
- **Armazenamento:** [Ex: Volume de dados requer Data Lake ou banco convencional?]
- **Latência de Rede:** [Ex: A solução exige resposta em milissegundos (Borda) ou segundos (Nuvem)?]

C.3 Dimensão: Viabilidade Científica

Instruções de Preenchimento

Esta dimensão avalia a robustez metodológica da solução. O objetivo é mitigar o risco de construir um modelo que funciona no laboratório, mas falha no mundo real devido a problemas de generalização ou instabilidade.

C.3.1 Adequação Metodológica e Estado da Arte

Análise da Abordagem:

- **Alinhamento com a Literatura:** A técnica escolhida (Ex: *Gradient Boosting*) é considerada o estado da arte para dados tabulares, conforme referências recentes (Ex: Grinsztajn et al., 2022).
- **Complexidade Justificada:** A escolha de um modelo complexo (Ex: Rede Neural) em detrimento de uma Regressão Linear se justifica pelo ganho de performance de observado na PoC?

C.3.2 Resultados da Prova de Conceito (PoC)

Modelo Testado	Métrica Principal	Desvio Padrão (CV)	Status
Baseline Humano (Referência)	70% (Estimado)	N/A	–
Modelo A (Regressão)	75%	±5%	Insuficiente
Modelo B (XGBoost)	**89%**	±**2**%	**Aprovado**

Análise Crítica de Erros (Error Analysis):
[Crucial: Descreva onde o modelo falha. Ex: "O modelo atinge 89% de acerto global, mas sua performance cai para 60% quando analisamos apenas processos rurais. Isso indica um viés de representatividade nos dados de treino."]

C.3.3 Riscos de Confiabilidade e Robustez

Instruções de Preenchimento

Avalie se o modelo é seguro e estável para operação contínua.

- **Generalização (Overfitting):** Houve discrepância significativa entre treino e teste? *[Ex: Treino 99% vs Teste 89% indica leve overfitting, controlado via regularização.]*
- **Explicabilidade (XAI):** O problema exige que a decisão seja justificada ao cidadão? *[ ] Sim. O modelo "Caixa Preta"(Black Box) é inaceitável. Será necessário acoplar técnicas de XAI (SHAP/LIME) para gerar justificativas legais. [ ] Não. O foco é apenas triagem interna.*
- **Estabilidade Temporal (Concept Drift):** Os padrões mudam rapidamente? *[Ex: Em detecção de fraude, o padrão muda a cada 3 meses. O ciclo de vida do modelo deve prever re-treino automático trimestral.]*

C.3.4 2.2 Riscos de Modelagem e Generalização

Instruções de Preenchimento

O modelo funciona apenas no laboratório ou vai funcionar na vida real?

- **Risco de Sobreajuste (Overfitting):** [Ex: O modelo decorou os dados de treino? Houve validação cruzada?]
- **Dependência de Variáveis Sensíveis:** [Ex: O modelo depende de "Gênero"ou "Bairro"para acertar? Isso gera viés?]

- **Estabilidade Temporal:** [Ex: O padrão de comportamento muda drasticamente a cada mês?]

C.4 Dimensão: Viabilidade Operacional

Instruções de Preenchimento

Foco na "vida real". Como a solução será usada e mantida dentro do órgão público?

C.4.1 3.1 Integração com Legado e Fluxos de Trabalho

- **Sistemas Legados:** [Ex: É tecnicamente possível integrar via API com o sistema do órgão? Existe documentação?]
- **Adaptação de Processo:** [Ex: O fluxo de trabalho dos servidores precisará mudar? A equipe aceita a mudança?]

C.4.2 3.2 Capacidade de Manutenção e Sustentação

Instruções de Preenchimento

Quem cuida da IA quando a Fábrica sair?

- **Equipe Disponível:** [Ex: O órgão possui profissionais de TI para manter a API no ar?]
- **Necessidade de Capacitação:** [Ex: Será necessário treinar os usuários finais para interpretar as predições?]

C.5 4. Consolidação de Riscos e Limitações

Instruções de Preenchimento

Torne explícitos os trade-offs da solução.

Principais Riscos Identificados

1. **Risco Técnico:** Dependência de qualidade dos dados manuais inseridos na ponta.
2. **Risco Científico:** Degradação rápida do modelo (Drift) exigindo re-treino mensal.
3. **Risco Operacional:** Resistência cultural dos auditores em confiar na máquina.

C.6 5. Parecer Final para Decisão de MVP

Com base na avaliação das três dimensões (Técnica, Científica e Operacional), a equipe recomenda:

[ ] **VIÁVEL:** Avançar para o desenvolvimento do MVP. Os riscos são gerenciáveis e a tecnologia é adequada.

[ ] **VIÁVEL COM RESTRIÇÕES:** Avançar, condicionando o início à resolução do impedimento: _____.

[ ] **INVIÁVEL :** Não avançar. O projeto apresenta riscos proibitivos na dimensão [**Técnica/Científica/Operacional**].

Responsável Técnico (Fábrica)	**Gestor do Órgão Demandante**
Validação das Dimensões	Ciência dos Riscos Operacionais

Referências Bibliográficas

[1] Saleema Amershi, Andrew Begel, Christian Bird, Robert DeLine, Harald Gall, Ece Kamar, Nachiappan Nagappan, Besmira Nushi, and Thomas Zimmermann. Software engineering for machine learning: A case study. In *Proceedings of the 41st International Conference on Software Engineering: Software Engineering in Practice (ICSE-SEIP)*. IEEE/ACM, 2019.

[2] Brasil. Projeto de Lei nó 2.338, de 2023. Senado Federal, 2023. Dispõe sobre o uso da Inteligência Artificial. Autoria: Senador Rodrigo Pacheco.

[3] BRASIL. Ministério da Gestão e da Inovação em Serviços Públicos. *Framework para a Autoavaliação de Impacto Ético em Inteligência Artificial no Setor Público Federal*. Secretaria de Governo Digital, Brasília, 2022.

[4] Marcos Kalinowski, Tatiana Escovedo, and Hugo Villamizar. *Engenharia de Software para Ciência de Dados: um guia de boas práticas com ênfase na construção de sistemas de machine learning em Python*. Casa do Código, São Paulo, SP, Brasil, 2024. ISBN (digital): 978-85-5519-335-4.

[5] Marcos Kalinowski, Hélio Lopes, Alex F Teixeira, Gabriel S Cardoso, André Kuramoto, Bruno Itagyba, Solon T Batista, Juliana A Pereira, Thuener Silva, Jorge A Warrak, et al. Lean r&d: An agile research and development approach for digital transformation. In *International Conference on Product-Focused Software Process Improvement (PROFES)*, pages 106–124. Springer, 2020.

[6] Neoklis Polyzotis, Sudip Roy, Steven Euijong Whang, and Martin Zinkevich. Data management challenges in production machine learning. In *Proceedings of the 2017 ACM International Conference on Management of Data (SIGMOD)*. ACM, 2017.

[7] David Sculley, Gary Holt, Daniel Golovin, Eugene Davydov, Todd Phillips, Dietmar Ebner, Vinay Chaudhary, Michael Young, Jean-François Crespo, and Dan Dennison. Hidden technical debt in machine learning systems. In *Proceedings of the 28th International Conference on Neural Information Processing Systems*, volume 2, pages 2503–2511. MIT Press, 2015.

[8] Colin Shearer. The crisp-dm model: The new blueprint for data mining. *Journal of Data Warehousing*, 5(1):13–22, 2000. Introdução ao modelo CRISP-DM (Cross-Industry Standard Process for Data Mining).

[9] Hugo Villamizar, Marcos Kalinowski, Hélio Lopes, and Daniel Mendez. Identifying concerns when specifying machine learning-enabled systems: A perspective-based approach. *The Journal of Systems & Software*, 213:112053, 2024.

[10] Rüdiger Wirth and Jochen Hipp. Crisp-dm: Towards a standard process model for data mining. In *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining*, 2000.

[11] Ian H. Witten, Eibe Frank, Mark A. Hall, and Christopher J. Pal. *Data Mining: Practical Machine Learning Tools and Techniques*. Morgan Kaufmann, Boston, MA, 4 edition, 2016.